Análisis Exploratorio y Modelado Predictivo
de Accidentes de Tráfico en Madrid (2024)

1. Vista previa del cuaderno Jupyter

El cuaderno estructura el análisis en dos grandes bloques:

1. **Análisis Exploratorio de Datos (EDA)**: carga, limpieza, análisis univariante/bivariante, sesgo geográfico y respuesta a la pregunta de negocio sobre franjas horarias de mayor gravedad.
2. **Modelo de Regresión Logística**: predicción de la variable positiva_alcohol a partir de predictores categóricos y numéricos, evaluación de métricas e interpretación de coeficientes.

El flujo de trabajo sigue una secuencia lógica: importación de librerías (pandas, seaborn, matplotlib, scikit-learn y un módulo propio AlcoholLogisticModel), inspección del dataset, limpieza de tipos y nulos, generación de visualizaciones (heatmaps, barras, líneas) y, finalmente, entrenamiento y evaluación del modelo.

Objetivo principal del análisis: averiguar en qué franja horaria se producen los accidentes con mayor gravedad y qué condiciones (estado meteorológico, tipo de accidente, etc.) pueden influir en ello.

2. Resumen del dataset

El fichero accidentes.csv contiene registros de accidentes de tráfico ocurridos en la ciudad de Madrid durante el año 2024 (con algunos expedientes residuales de finales de 2023). Cada fila representa a una persona implicada en un accidente, por lo que un mismo expediente puede generar múltiples filas.

Dimensiones y estructura

El dataset tiene 49.340 filas y 19 columnas. A continuación se resumen las variables principales:

Columna	Descripción
num_expediente	Identificador único del expediente del accidente
fecha / hora	Fecha (dd/mm/yyyy) y hora del siniestro
localizacion / numero	Dirección o cruce y número de portal
cod_distrito / distrito	Código y nombre del distrito municipal (21 distritos)
tipo_accidente	Tipo de siniestro (colisión, alcance, atropello, caída, etc.)
estado_meteorologico	Condiciones climáticas (despejado, lluvia, nublado…)

tipo_vehiculo	Categoría del vehículo (turismo, motocicleta, bicicleta…)
tipo_persona	Rol: Conductor, Pasajero o Peatón
rango_edad / sexo	Grupo de edad y sexo de la persona implicada
cod_lesividad / lesividad	Código y descripción de la gravedad de la lesión
coordenada_x/y_utm	Coordenadas UTM del lugar del accidente
positiva_alcohol	Resultado de la prueba de alcohol (S/N)
positiva_droga	Resultado de la prueba de drogas (prácticamente vacío)

Cifras clave:

- ≈ 20.698 expedientes únicos (accidentes distintos).
- Distrito con más registros: Puente de Vallecas (~4.000 filas).
- Tipo de accidente más frecuente: colisión fronto-lateral (~13.245 registros).
- Vehículo predominante: turismo (~33.874 registros).
- Rol más común: conductor (~39.563 registros).
- Positivos en alcohol: minoritarios frente a negativos (desbalance de clases).
-

3. Explicación de la limpieza del EDA

La fase de limpieza se realizó para garantizar la coherencia de tipos de datos, eliminar ruido de codificación y tratar valores ausentes de forma controlada. Los pasos principales fueron:

3.1. Renombrado de columnas

Debido a problemas de codificación, las columnas estado_meteorológico y num_expediente presentaban caracteres corruptos (estado_meteorológicó, ï»¿num_expediente). Se renombraron a estado_meteorologico y num_expediente respectivamente.

3.2. Conversión de tipos

- numero, cod_distrito, cod_lesividad, coordenada_x_utm y coordenada_y_utm se convirtieron a numérico (enteros), rellenando nulos con 0 cuando procedía.
- fecha se transformó a datetime con formato %d/%m/%Y.
- hora se recortó a los primeros 5 caracteres (HH:MM) para facilitar el posterior cálculo de franjas horarias.
-

3.3. Limpieza de caracteres invisibles

En la columna distrito se eliminaron caracteres de control (rango \x80-\x9f) mediante expresión regular, evitando errores en agrupaciones y visualizaciones posteriores.

3.4. Tratamiento de valores nulos

Se identificaron nulos significativos en:

- estado_meteorologico: ~5.916 nulos
- lesividad / cod_lesividad: ~21.996 nulos (personas sin asistencia sanitaria registrada)
- positiva_droga: ~49.137 nulos (casi toda la columna)
- tipo_vehiculo y positiva_alcohol: cientos de nulos

Las variables categóricas tipo_accidente, estado_meteorologico, tipo_vehiculo, lesividad y positiva_alcohol se imputaron con el valor «Desconocido». La columna positiva_droga se eliminó por carecer de información útil (más del 99 % de nulos).

Como resultado, el dataset quedó listo para el análisis exploratorio y el modelado, con tipos coherentes y nulos gestionados de forma explícita.

4. Explicación de análisis univariable y bivariable

Se realizaron múltiples cruces y distribuciones univariadas para comprender el perfil de los siniestros y de las personas implicadas.

4.1. Tipo de persona vs. tipo de accidente

Mediante un mapa de calor de porcentajes (crosstab normalizado por fila) se observó que los peatones concentran la gran mayoría de los atropellos, mientras que los conductores y pasajeros están mayoritariamente asociados a colisiones (fronto-laterales, laterales, alcances y múltiples). Esta relación es esperable y confirma la coherencia de los datos.

4.2. Rango de edad y gravedad

Se definió la variable binaria es_grave = 1 cuando cod_lesividad es 3 o 4 (ingreso superior a 24 horas o fallecimiento). Entre los conductores con edad conocida:

- El volumen absoluto de accidentes se concentra entre los 25 y 54 años.
- La tasa de gravedad relativa es más elevada en el grupo de 10 a 17 años, lo que apunta a una vulnerabilidad especial (posiblemente ligada a ciclomotores, bicicletas o VMU eléctricos).
-

4.3. Sexo y tipo de persona

Los hombres representan la mayoría de las personas implicadas. Por rol, los conductores son el grupo dominante; los peatones constituyen una minoría relativa pero concentran los atropellos y, en muchos casos, lesiones más graves.

4.4. Tipos de accidente más frecuentes

Predominan la colisión fronto-lateral y el alcance. Los accidentes por «solo salida de la vía» son residuales. Esta distribución orienta posibles intervenciones de seguridad vial hacia intersecciones y distancias de seguridad.

4.5. Alcohol y franja horaria

Se calculó el porcentaje de positivos en alcohol comparando la madrugada (00–06 h) con el resto del día. El resultado es contundente: la incidencia de alcohol positivo es claramente superior en la madrugada. Esta evidencia es central tanto para la pregunta de negocio como para el modelo predictivo.

4.6. Evolución mensual

La serie mensual muestra un mínimo en agosto (éxodo vacacional) y un máximo en diciembre (compras navideñas, fiestas y peor climatología). Este patrón estacional es coherente con la movilidad urbana de Madrid.

5. Explicación de análisis de sesgo geográfico

El análisis geográfico se abordó en dos dimensiones: volumen absoluto de accidentes por distrito y tasa de gravedad relativa.

5.1. Volumen de accidentes por distrito

Un gráfico de barras con los porcentajes de registros por distrito (sobre el total de Madrid) muestra que Puente de Vallecas y Centro superan claramente la media. Esto se explica, en buena medida, por la mayor densidad de población, de tráfico y de actividad comercial/nocturna en estos distritos.

5.2. Tasa de gravedad por distrito

Al calcular el porcentaje de accidentes graves (ingreso > 24 h o fallecidos) sobre el total de cada distrito, el ranking cambia. Distritos como Salamanca y Chamartín destacan negativamente: aunque no lideran el volumen absoluto, presentan una proporción elevada de siniestros severos, frecuentemente asociados a conducción nocturna y condiciones meteorológicas adversas.

Conclusión geográfica: el volumen y la gravedad no coinciden necesariamente. Las políticas de seguridad vial deben combinar medidas de reducción de exposición (donde hay más accidentes) con medidas de reducción de severidad (donde los accidentes son más graves).

6. Pregunta de negocio y conclusión

Pregunta formulada: *¿En qué franja horaria se producen los accidentes con mayor gravedad (ingreso superior a 24 horas o fallecidos) y qué condiciones (estado meteorológico, tipo de accidente, etc.) pueden influir en ello?*

Metodología

Se creó la variable franja_horaria agrupando la hora en cuatro intervalos: Madrugada (0–6), Mañana (6–12), Tarde (12–18) y Noche (18–24). Se cruzó la proporción de accidentes graves (es_grave) con la franja y el estado meteorológico mediante un gráfico de barras agrupadas.

Hallazgos

- La noche concentra la mayor proporción de accidentes graves, especialmente cuando el estado meteorológico aparece como «Se desconoce» o no está determinado.
- La madrugada también muestra tasas elevadas de gravedad, asociadas a lluvia intensa y cielo nublado.
- La menor visibilidad y las peores condiciones climáticas (lluvia, niebla) empeoran la conducción y aumentan la severidad de los siniestros en estas franjas.

Conclusión del EDA

- Los hombres y el rango de edad 25–54 años concentran el mayor volumen de siniestros; la tasa de gravedad es crítica en el grupo 10–17 años.
- Existe una relación clara entre la madrugada y la positividad en alcohol.
- Estacionalmente, diciembre es el pico y agosto el mínimo.
- Puente de Vallecas y Centro lideran el volumen; Salamanca y Chamartín destacan en gravedad relativa, ligada a conducción nocturna y clima adverso.

7. Explicación del modelo de regresión logística

El objetivo del modelado es predecir la variable binaria positiva_alcohol (S = 1, N = 0) exclusivamente para conductores. Se utiliza una regresión logística con regularización (parámetro C = 1.0), implementada en la clase AlcoholLogisticModel.

7.1. Preparación de datos

Filtros aplicados:

- tipo_persona == «Conductor»
- positiva_alcohol ∈ {«S», «N»} (se excluyen los «Desconocido»)

Predictores:

Categóricos: tipo_accidente, sexo, distrito, estado_meteorologico

Numérico: numero_hora (hora del día como entero 0–23)

Se realizó un train/test split estratificado (80 % / 20 %, random_state = 42) para preservar la proporción de positivos en ambos conjuntos.

8. Explicación de resultados de entrenamiento del modelo

Tras el entrenamiento sobre el conjunto de prueba, las métricas de evaluación reflejan el fuerte desbalance de clases (muy pocos positivos en alcohol respecto a los negativos):

Métrica	Interpretación
Precisión (Precision)	Muy baja: de las predicciones positivas, pocas son realmente positivas.
Sensibilidad (Recall)	Aceptable: el modelo captura aproximadamente dos tercios de los conductores realmente positivos en alcohol.
F1-score	Bajo, lastrado por la baja precisión.

Interpretación práctica: el modelo es útil como herramienta de cribado (alta sensibilidad) pero genera muchos falsos positivos. En un contexto operativo (por ejemplo, priorización de controles) podría servir para señalar franjas, distritos o tipos de accidente de mayor riesgo, siempre complementado con otras fuentes de información.

El desbalance de clases es el principal limitante. Técnicas de reequilibrio (oversampling, undersampling o class_weight) o umbrales de decisión ajustados podrían mejorar el equilibrio entre precisión y sensibilidad en iteraciones futuras.

9. Explicación de la importancia de las variables

A partir de los coeficientes de la regresión logística se ordenaron las variables (tras one-hot encoding de las categóricas) por su peso en el modelo:

Variables que más incrementan el riesgo de positivo en alcohol:

Los tipos de accidente asociados a pérdida de capacidad motora y de concentración del conductor (por ejemplo, choques contra obstáculo fijo, salidas de vía o colisiones en circunstancias de menor control) presentan coeficientes positivos elevados. Determinados distritos también aumentan de forma significativa la probabilidad de que el accidente esté asociado a alcohol positivo, reflejando patrones espaciales de consumo y movilidad nocturna.

Variables que más disminuyen el riesgo:

Categorías de accidente más «cotidianas» (alcances en horario diurno, colisiones laterales en condiciones de tráfico denso) y ciertos distritos con menor actividad nocturna o de ocio tienden a

reducir la probabilidad de positivo. La hora del día, como variable numérica, también contribuye: las horas de madrugada empujan el riesgo al alza.

En resumen, el modelo confirma lo observado en el EDA: el alcohol positivo se asocia a tipos de siniestro que denotan pérdida de control, a franjas nocturnas/madrugada y a zonas concretas de la ciudad. Estas variables de mayor peso son las candidatas prioritarias para campañas de prevención y para el diseño de controles de alcoholemia.